

大学生创新训练项目技术报告

基于时空注意力与联邦学习的 配电网负荷预测

PA-STFed：面向 SmartDS 合成微观配电网的物理-功能双图
时空联邦预测框架

项目题目：基于时空注意力与联邦学习的配电网负荷预测

数据场景：NREL/OEDI SmartDS 合成配电网处理数据

摘要

针对配电网中多节点负荷的短期预测与跨区域数据不可直接汇集问题，本文以 NREL/OEDI SmartDS 合成配电网处理数据为对象，提出一套可检验、可复现的研究设计。原始数据包含 273 个拓扑节点、35 040 个 15 分钟采样时刻及节点邻接关系；其中仅 92 个节点具有非零负荷，且存在 57 个连通分量、181 个恒零节点和 56 条唯一负荷曲线。该事实决定了模型不能把拓扑完整性、节点独立性或真实气象驱动作为既定前提。

在方法上，本文设计 PA-STFed (Physical-Adaptive Spatio-Temporal Federated Network)：以边感知物理图注意力编码可审计的拓扑传播，以客户端本地可学习的静态功能图刻画跨时段负荷共性，以因果 Temporal Transformer 建模历史窗口内的时间依赖，并以两级门控完成空间分支和时空分支融合。联邦优化采用共享编码器与本地个性化参数，利用 FedProx 近端项抑制强 Non-IID 条件下的客户端漂移。差分隐私作为独立实验阶段，通过更新裁剪、高斯机制、可选安全聚合及 Rényi DP accountant 报告 (ϵ, δ) 预算，而不把“数据不离开客户端”误称为形式化隐私保证。

本文给出从数据审计、图构造、损失函数、联邦交互到统计推断的完整公式，设计结构、联邦、隐私、拓扑和重复曲线敏感性实验矩阵，并对已有单次初步消融结果作边界明确的解释。报告的目标不是预先宣称模型最优，而是形成能够经由基线、消融、置信区间和复现实验支撑的结项证据链。

关键词：配电网负荷预测；时空注意力；图注意力网络；自适应图学习；联邦学习；FedProx；差分隐私

目录

1	研究定位、问题边界与科学问题	1
1.1	研究目标	1
1.2	研究假定、证据等级与禁止外推	1
1.3	科学问题	2
1.4	相关研究依据与方法谱系	2
2	数据审计与预测任务定义	3
2.1	原始字段、规模与启发式拓扑填充	3
2.2	样本、掩码与标准化	4
2.3	客户端划分与 Non-IID 量化	5
3	PA-STFed 时空预测模型	5
3.1	总体结构	5
3.2	边感知物理图注意力	5
3.3	客户端本地静态功能图	7
3.4	双图空间门控与因果时间编码	7
3.5	时空融合、个性化预测头与训练损失	8
4	联邦优化、个性化与差分隐私	9
4.1	FedProx 共享骨干	9
4.2	威胁模型与正式隐私机制	9
4.3	通信与计算记录	11
5	实验设计、评价指标与统计规范	11
5.1	分阶段验证原则	11
5.2	评价指标	12
5.3	统计检验与复现协议	12
5.4	推荐起始配置	13
6	已有初步结果的规范解读与最终模型决策	13
6.1	单次消融结果与负协同诊断协议	13
6.1.1	时空双级门控系数分布与饱和度诊断协议	14

7 职责分配、八周计划与交付规范	15
7.1 三人职责分配	15
7.2 八周实施计划	16
7.3 结果文件与验收清单	16
8 风险、局限性与结论	17
8.1 主要风险与处置	17
8.2 结论	17
A 符号说明	18

1 研究定位、问题边界与科学问题

1.1 研究目标

本项目研究对象是微观配电网处理数据中的多节点短期负荷预测，而非省级宏观输电负荷预测。设每个节点以 15 分钟为间隔记录负荷，使用过去 $L = 96$ 个采样点（24 小时）预测未来 $H = 12$ 个采样点（3 小时）。研究目标包括：

1. 建立可复现的数据审计、时间切分、节点掩码和图构造流程，避免恒零节点与重复曲线造成虚假精度提升；
2. 构建同时利用可审计物理连接和数据驱动功能关联的时空预测骨干，并通过逐模块消融判断复杂模块是否带来稳定收益；
3. 构造具有可量化 Non-IID 特征的联邦仿真环境，比较 Local-only、FedAvg、FedProx 与个性化本地头；
4. 在固定隐私会计协议下评估差分隐私的精度-隐私-通信折中，而不作超出威胁模型的安全承诺。

1.2 研究假定、证据等级与禁止外推

本项目的适用边界是方法有效性判断的组成部分，而非结果讨论中的附加免责声明。主实验遵守以下结构化约束；任何偏离均须另立敏感性实验并保留独立配置。

- B1. 合成场景边界：**当前验证对象仅为 NREL/OEDI SmartDS 合成配电网及其本地处理文件。实验结果不得直接外推为真实配电台区、真实智能电表群或现场运行结果，也不得据此声称完成工程部署验证。
- B2. 拓扑冻结边界：**原始无向图 $\mathcal{G}^{\text{raw}}$ 含 57 个连通分量。除第 2.1 节规定的启发式拓扑填充（Heuristic Topology Imputation）生成 $\mathcal{G}^{\text{inf}}$ 外，主实验不得任意增删边；原始图、启发式填充图和预注册扰动图必须分开报告。
- B3. 时间与外源特征边界：**处理文件没有可核验的绝对时间戳。模型不得引入真实日期、星期、法定节假日、天气或任何依赖绝对日历对齐的外部特征；仅允许使用由样本顺序和采样间隔确定的相对位置或周期编码，并须明确其不对应真实日历标签。
- B4. 联邦语义边界：**将空间节点划分为 K 个客户端只是合成网络上的空间聚合验证，用于构造可量化的统计异构；这些客户端不代表真实独立法人、电网运营商或具有物理隔离边界的配电系统。

表 1 规定全文的证据等级。所有结项陈述必须标记其属于数据事实、单次初步结果、方法设计或多随机种子验证结论中的哪一类。

表 1: 证据等级与写作约束

等级	含义	本项目允许的表述
A: 数据事实	可由原始 NPZ 文件直接复核	“ $35\,040 \times 273$ 的负荷矩阵, 92 个非零负荷节点”
B: 初步结果	现有单次运行产生, 尚未统计复验	“边编码呈现初步正向信号, 需以多种子确认”
C: 方法设计	已给出公式、实现接口与实验协议	“拟采用边感知 GAT 与 FedProx”
D: 验证结论	通过预注册对照、五个种子与统计检验获得	“在指定协议下显著优于对照”

以下表述被主动排除: SmartDS 被称为真实实测台区数据; 启发式拓扑填充边被称为官方网络真值; 联邦学习被称为自动满足差分隐私; 单次运行最优值被称为普遍最优。该边界保证结论强度与证据等级一致。

1.3 科学问题

- 1. **RQ1:** 在拓扑断裂、恒零节点和重复曲线并存的条件下, 如何定义不泄漏未来信息的多步预测任务与有效评估样本?
- 2. **RQ2:** 边属性感知的物理图和客户端本地静态功能图能否分别、且互补地改善预测误差?
- 3. **RQ3:** 在 Transformer 已建模时间依赖时, 空间-时间门控是否优于简单相加或全部模块堆叠?
- 4. **RQ4:** 面对区域间强 Non-IID, FedProx 与本地预测头能否同时改善平均误差、最差客户端误差和收敛稳定性?
- 5. **RQ5:** 在明确的用户级邻接关系、裁剪阈值、采样率与 accountant 下, 隐私预算收紧如何影响预测和通信代价?

1.4 相关研究依据与方法谱系

SmartDS 的核心价值是提供具有配电层级结构和可扩展 OpenDSS 模型的合成电网研究环境, 其设计目标与数据入口分别见文献 [1, 2]。因此, 本项目可以讨论微观配电结构上的多节点负荷建模, 但其外部有效性应限定为合成场景验证。

空间建模以图注意力网络的邻居加权机制为基础 [4]，图结构可学习模型 GWNet、AGCRN 与 MTGNN 为静态自适应关系学习及其强基线设计提供依据 [5, 6, 7]；配电负荷场景中的时空嵌入研究说明节点关联与时间依赖联合建模具有合理性 [3]。OGIF-GAT 与多层时空相关图注意力提供了边信息融合和时空融合的迁移启发 [10, 11]，但二者原任务是交通流预测，本项目仅迁移其通用机制，不宣称完成原论文复现。长时间依赖由标准 Transformer 注意力与残差编码结构承担 [8]，因此不再把与其功能重叠的 T-GAT 固定纳入主模型。

联邦优化以 FedAvg 为标准基线 [12]，以 FedProx 的近端正则处理系统和统计异构 [13]，并参考共享表示与本地头分离的个性化思想 [14]。住宅负荷预测领域已有研究表明，联邦训练能够在不直接汇集原始序列的条件下开展协作预测 [15, 16]，但这不构成形式化隐私保证。本文的差分隐私机制建立在梯度/更新裁剪与高斯机制 [17]、Rényi DP 会计 [18] 及安全聚合协议 [19] 的明确组合之上。

2 数据审计与预测任务定义

2.1 原始字段、规模与启发式拓扑填充

本报告仅使用已经核验的 SmartDS 处理文件字段，见表 2。35 040 = 365×96 表明样本覆盖连续 365 天的相对时间序列；原文件不包含可验证的真实起始日期、时区、天气、节假日或负荷物理单位。因此，模型只能使用相对日周期和相对周周期编码，不能虚构天气、星期标签或节假日特征。

表 2: SmartDS 本地 NPZ 数据审计结果

字段	形状或数量	已核验含义与使用约束
load_ts	(35 040, 273)	15 分钟负荷序列；只有 92 列非零；仅这些节点进入预测误差计算
node_coords	(273, 2)	节点坐标；可用作几何距离和位置嵌入，不能解释为精确电气线路长度
adj	(273, 273)	二值邻接矩阵；对应 216 条无向边和 57 个连通分量
edge_index	(2, 432)	双向存储的边索引，即 216 条无向边
node_ids	(273,)	节点标识；不能单独被当作可泛化的连续数值特征
唯一非零曲线	56 条	92 个负荷节点中存在完全重复曲线，须进行重复组敏感性分析

将原始无向图记为

$$\mathcal{G}^{\text{raw}} = (\mathcal{V}, \mathcal{E}^{\text{raw}}), \quad |\mathcal{V}| = 273, \quad |\mathcal{E}^{\text{raw}}| = 216. \quad (1)$$

其连通分量集合固定记为

$$\mathfrak{C} = \{\mathcal{C}_1, \dots, \mathcal{C}_{57}\}, \quad \mathcal{C}_a \cap \mathcal{C}_b = \emptyset \quad (a \neq b), \quad \bigcup_{a=1}^{57} \mathcal{C}_a = \mathcal{V}. \quad (2)$$

为消除跨分量建图的算法黑盒，本文把唯一允许的连接规则定义为**启发式拓扑填充 (Heuristic Topology Imputation)**。令 $\mathbf{c}_i \in \mathbb{R}^2$ 为节点 i 的坐标，构造以原始连通分量为顶点的完全加权分量图，其边权为

$$\delta_{ab} = \min_{i \in \mathcal{C}_a, j \in \mathcal{C}_b} \|\mathbf{c}_i - \mathbf{c}_j\|_2, \quad 1 \leq a < b \leq 57. \quad (3)$$

在该分量图上运行确定性的 Kruskal 最小生成树算法：候选边首先按 (δ_{ab}, a, b) 升序排列；距离相等时依次以分量编号 a, b 消歧。记所得分量级最小生成树为 $\mathcal{T}_{\mathfrak{C}}$ 。对每条 $(a, b) \in \mathcal{T}_{\mathfrak{C}}$ ，选取达到式 (3) 最小值的节点对；若存在多个最小节点对，则按 (i, j) 的字典序选择唯一节点对

$$(i_{ab}^*, j_{ab}^*) = \underset{\substack{i \in \mathcal{C}_a, j \in \mathcal{C}_b \\ \|\mathbf{c}_i - \mathbf{c}_j\|_2 = \delta_{ab}}}{\text{lexmin}} (i, j). \quad (4)$$

由此得到桥接边集合及启发式填充图

$$\mathcal{E}^{\text{bridge}} = \{(i_{ab}^*, j_{ab}^*) : (a, b) \in \mathcal{T}_{\mathfrak{C}}\}, \quad |\mathcal{E}^{\text{bridge}}| = 56, \quad (5)$$

$$\mathcal{E}^{\text{inf}} = \mathcal{E}^{\text{raw}} \cup \mathcal{E}^{\text{bridge}}, \quad \mathcal{G}^{\text{inf}} = (\mathcal{V}, \mathcal{E}^{\text{inf}}), \quad |\mathcal{E}^{\text{inf}}| = 272. \quad (6)$$

该过程只在分量层面最小化坐标桥接代价，既不恢复导线真值，也不证明跨分量节点之间存在真实电气连接。主实验必须冻结节点坐标、分量编号、排序规则和式 (4) 的消歧规则，并保存 56 条桥接边清单及其哈希。 $\mathcal{G}^{\text{raw}}$ 与 $\mathcal{G}^{\text{inf}}$ 必须分开配置、单独报告并接受拓扑敏感性检验。

2.2 样本、掩码与标准化

令 $\mathcal{V}_{\ell} \subset \mathcal{V}$ 表示非零负荷节点集合， $|\mathcal{V}_{\ell}| = N_{\ell} = 92$ ； $m_i = \mathbb{I}(i \in \mathcal{V}_{\ell})$ 为目标掩码。以预测原点 τ 构造一个样本：

$$\mathbf{X}_{\tau} = [\mathbf{x}_{\tau-L+1}, \dots, \mathbf{x}_{\tau}] \in \mathbb{R}^{L \times N \times F}, \quad \mathbf{Y}_{\tau} = [\mathbf{y}_{\tau+1}, \dots, \mathbf{y}_{\tau+H}] \in \mathbb{R}^{H \times N}, \quad (7)$$

其中 N 是该客户端参与编码的节点数， F 是输入维数。对于节点 i 、时刻 t ，输入向量定义为

$$\mathbf{x}_{t,i} = \left[\tilde{\ell}_{t,i}, \sin\left(\frac{2\pi(t \bmod 96)}{96}\right), \cos\left(\frac{2\pi(t \bmod 96)}{96}\right), \sin\left(\frac{2\pi t}{672}\right), \cos\left(\frac{2\pi t}{672}\right) \right]^{\top}, \quad (8)$$

其中 $672 = 7 \times 96$ 表示相对周周期，不对应任何具体星期。每个节点只使用训练段统计量作稳健标准化：

$$\tilde{\ell}_{t,i} = \frac{\ell_{t,i} - \text{median}(\ell_{\text{train},i})}{\max\{\text{IQR}(\ell_{\text{train},i}), \epsilon_s\}}, \quad \epsilon_s > 0. \quad (9)$$

时间上按 70%/10%/20% 顺序划分训练、验证与测试段。滑动窗口不允许跨越分割边界，早停和超参数选择只使用验证段，测试段仅用于最终一次评估。

令 $\mathcal{G}(i) = \{j \in \mathcal{V}_\ell : \ell_{:,j} = \ell_{:,i}\}$ 为节点 i 的完全重复曲线组。为避免同一曲线被重复计数，定义 $w_i = 1/|\mathcal{G}(i)|$ ，任意带掩码的误差汇总均采用 $m_i w_i$ 加权。正式结果须同时给出 92 节点全量评估、56 条唯一曲线折叠评估和重复组加权评估。

2.3 客户端划分与 Non-IID 量化

将包含负荷节点的原始连通分量视为原子区域，再在明确的坐标邻近与图连通规则下组合为 K 个联邦客户端。主实验取 $K = 8$ ，并以 $K \in \{4, 8, 12\}$ 作敏感性分析；这是联邦**仿真**，不声称数据天然来自 K 个独立运营主体。

对客户端 k 的训练负荷经验分布 P_k ，以 Jensen–Shannon 散度量化幅值异构性：

$$\text{JSD}(P_k, P_{k'}) = \frac{1}{2} D_{\text{KL}} \left(P_k \left\| \frac{P_k + P_{k'}}{2} \right\| \right) + \frac{1}{2} D_{\text{KL}} \left(P_{k'} \left\| \frac{P_k + P_{k'}}{2} \right\| \right). \quad (10)$$

同时，将每条日负荷曲线归一化后计算一阶 Wasserstein 距离、峰谷比、均值、方差和日内峰值时刻分布。只有当这些量与客户端划分一起报告时，FedProx 的异构性动机才可被检验。

3 PA-STFed 时空预测模型

3.1 总体结构

模型由边感知物理图注意力、客户端本地静态功能图、因果 Temporal Transformer、两级门控与客户端个性化预测头构成。共享变换参数向量记为 θ ，客户端 k 的本地参数向量记为 ϕ_k ；后者包含静态功能关系嵌入和本地预测头，不参与服务器聚合。所有图分支只在客户端可见的节点和历史窗口内计算，服务器从不接收原始张量 $\mathbf{X}_{\tau,k}$ 、节点时间序列、功能关系矩阵或注意力矩阵。

3.2 边感知物理图注意力

对预注册选择的图

$$\mathcal{G}^P \in \{\mathcal{G}^{\text{raw}}, \mathcal{G}^{\text{inf}}\}, \quad (11)$$




图 1: PA-STFed 的共享时空编码器与本地个性化预测头。

以 $d_{ij}^{\text{hop}}(\mathcal{G}^P)$ 表示节点 i, j 在该图上的最短跳数，并令 Π_{ij}^P 为字典序消歧后选定的一条最短路径。半径 R_P 内的消息传递邻域为

$$\mathcal{N}^P(i) = \left\{ j \in \mathcal{V}_k : d_{ij}^{\text{hop}}(\mathcal{G}^P) \leq R_P \right\}. \quad (12)$$

对每个候选节点对 (i, j) 构造边属性向量

$$\mathbf{r}_{ij}^P = \left[d_{ij}^{\text{hop}}(\mathcal{G}^P), d_{ij}^{\text{geo}}, n_{ij}^{\text{inf}}(\Pi_{ij}^P) \right]^\top, \quad n_{ij}^{\text{inf}}(\Pi_{ij}^P) = \sum_{e \in \Pi_{ij}^P} \mathbb{I}(e \in \mathcal{E}^{\text{bridge}}), \quad (13)$$

其中

$$d_{ij}^{\text{geo}} = \|\mathbf{c}_i - \mathbf{c}_j\|_2 \quad (14)$$

仅为坐标空间中的位置先验。对于来自不同原始连通分量的节点， $d_{ij}^{\text{hop}}(\mathcal{G}^{\text{raw}}) = +\infty$ ，因而该节点对不进入原始图消息传递； $\mathcal{G}^{\text{inf}}$ 连通后，所有节点对的跳数均为有限值，且跨分量路径可能包含一个或多个启发式填充桥边。因此，两图的有限跳数经验分布

$$\hat{F}_P(x) = \frac{1}{|\mathcal{D}_P|} \sum_{d \in \mathcal{D}_P} \mathbb{I}(d \leq x), \quad \mathcal{D}_P = \left\{ d_{ij}^{\text{hop}}(\mathcal{G}^P) : i < j, d_{ij}^{\text{hop}}(\mathcal{G}^P) < \infty \right\} \quad (15)$$

具有不同的样本基数、集中趋势与尾部。实验必须分别保存 $\hat{F}_{\text{raw}}$ 和 $\hat{F}_{\text{inf}}$ 的分位数；若对跳数进行标准化，也须分别冻结并记录对应图的变换参数，禁止混用统计量。式 (13) 中的跳数与坐标距离仅表示图拓扑关系先验与位置先验，绝非导线物理长度、真实电气阻抗、电抗或经潮流校准的电气距离。

给定时刻 t 的节点嵌入 $\mathbf{h}_{t,i}^0$ ，第 m 个注意力头的计算为

$$\mathbf{u}_{t,i}^{P,m} = \mathbf{W}^{P,m} \mathbf{h}_{t,i}^0, \quad (16)$$

$$e_{t,ij}^{P,m} = \text{LeakyReLU} \left((\mathbf{a}^{P,m})^\top [\mathbf{u}_{t,i}^{P,m} \parallel \mathbf{u}_{t,j}^{P,m}] + (\mathbf{b}^{P,m})^\top \varphi(\mathbf{r}_{ij}^P) \right), \quad (17)$$

$$\alpha_{t,ij}^{P,m} = \frac{\exp(e_{t,ij}^{P,m})}{\sum_{q \in \mathcal{N}^P(i)} \exp(e_{t,iq}^{P,m})}, \quad (18)$$

$$\mathbf{o}_{t,i}^{P,m} = \sigma \left(\sum_{j \in \mathcal{N}^P(i)} \alpha_{t,ij}^{P,m} \mathbf{u}_{t,j}^{P,m} \right), \quad (19)$$

$$\mathbf{h}_{t,i}^P = \mathbf{o}_{t,i}^{P,1} \parallel \mathbf{o}_{t,i}^{P,2} \parallel \cdots \parallel \mathbf{o}_{t,i}^{P,M_P}. \quad (20)$$

其中 $\varphi(\cdot)$ 为边属性 MLP, $\parallel$ 表示多头拼接, σ 为非线性函数。边编码消融必须只改变 $\varphi(\mathbf{r}_{ij}^P)$, 其他训练预算保持一致。

3.3 客户端本地静态功能图

主实验取 $K = 8$ 时, 每个客户端通常仅含 11–12 个非零负荷节点。在此类微型子图上逐时刻重算稠密相似度并执行动态 TopK, 会重复支付图构造成本, 而且有限节点使邻居排序易受批次噪声扰动, 增加结构退化和过拟合风险。因此, 功能关系改为客户端独享、跨时段共享的可学习静态有向图。

令 $N_k = |\mathcal{V}_k \cap \mathcal{V}_\ell|$, 并为客户端 k 定义两组本地节点嵌入

$$\mathbf{E}_{k,1}, \mathbf{E}_{k,2} \in \mathbb{R}^{N_k \times d_a}. \quad (21)$$

静态关系得分和行归一化邻接矩阵为

$$\mathbf{S}_k^A = \text{ReLU}(\mathbf{E}_{k,1} \mathbf{E}_{k,2}^\top), \quad (22)$$

$$\mathbf{A}_k^A = \text{softmax}_{\text{row}}(\mathbf{S}_k^A + \mathbf{M}_k^{\text{diag}}), \quad (23)$$

$$[\mathbf{M}_k^{\text{diag}}]_{ij} = \begin{cases} -\infty, & i = j, \\ 0, & i \neq j. \end{cases} \quad (24)$$

其中非对称乘积允许学习方向性行为依赖; 对角掩码避免功能分支退化为恒等自环。给定共享输入状态 $\mathbf{h}_{t,j}^0$, 功能图聚合为

$$\mathbf{h}_{t,i}^A = \sigma \left(\sum_{j \in \mathcal{V}_k} [\mathbf{A}_k^A]_{ij} \mathbf{W}_A \mathbf{h}_{t,j}^0 \right). \quad (25)$$

$\mathbf{E}_{k,1}$ 与 $\mathbf{E}_{k,2}$ 属于 ϕ_k , 始终保留在客户端; 共享变换 $\mathbf{W}_A$ 属于 θ 。功能图不得跨客户端拼接, 也不能作为真实电气连接的证据。相较逐时刻重构, 图构建本身的时间复杂度由 $\mathcal{O}(TN_k^2)$ 降为每次参数更新中的 $\mathcal{O}(N_k^2)$; 式 (25) 的逐时刻消息传递仍有时间相关成本, 不能误报为整体编码复杂度消除了因子 T 。静态参数在全部训练时段共同估计, 因而更适于捕捉微型子图节点间跨时段稳定的用电共性。

3.4 双图空间门控与因果时间编码

两图分支由节点-时刻级门控融合:

$$\gamma_{t,i} = \text{sigmoid}(\mathbf{W}_\gamma [\mathbf{h}_{t,i}^P \parallel \mathbf{h}_{t,i}^A] + \mathbf{b}_\gamma), \quad (26)$$

$$\mathbf{h}_{t,i}^S = \gamma_{t,i} \odot \mathbf{h}_{t,i}^P + (1 - \gamma_{t,i}) \odot \mathbf{h}_{t,i}^A. \quad (27)$$

应报告 $\gamma_{t,i}$ 的均值、标准差和分位数; 若长期饱和于 0 或 1, 说明一个分支可能冗余。

对每个节点，将 L 个空间状态加上可学习位置嵌入 $\mathbf{p}_t$ 输入因果 Transformer：

$$\mathbf{z}_{i,t}^0 = \mathbf{h}_{t,i}^S + \mathbf{p}_t, \quad (28)$$

$$\mathbf{Q}_i^{(\ell)} = \mathbf{Z}_i^{(\ell-1)} \mathbf{W}_\ell^Q, \quad \mathbf{K}_i^{(\ell)} = \mathbf{Z}_i^{(\ell-1)} \mathbf{W}_\ell^K, \quad \mathbf{V}_i^{(\ell)} = \mathbf{Z}_i^{(\ell-1)} \mathbf{W}_\ell^V, \quad (29)$$

$$\mathbf{A}_i^{(\ell)} = \text{softmax} \left(\frac{\mathbf{Q}_i^{(\ell)} (\mathbf{K}_i^{(\ell)})^\top}{\sqrt{d_k}} + \mathbf{M} \right), \quad M_{uv} = \begin{cases} 0, & u \geq v, \\ -\infty, & u < v, \end{cases} \quad (30)$$

$$\tilde{\mathbf{Z}}_i^{(\ell)} = \text{LN} \left(\mathbf{Z}_i^{(\ell-1)} + \mathbf{A}_i^{(\ell)} \mathbf{V}_i^{(\ell)} \right), \quad (31)$$

$$\mathbf{Z}_i^{(\ell)} = \text{LN} \left(\tilde{\mathbf{Z}}_i^{(\ell)} + \text{FFN}(\tilde{\mathbf{Z}}_i^{(\ell)}) \right). \quad (32)$$

其中掩码 $\mathbf{M}$ 禁止未来时刻参与注意力。取最后一个历史状态 $\mathbf{h}_i^T = \mathbf{z}_{i,L}^{(L_T)}$ 作为时间表示。

3.5 时空融合、个性化预测头与训练损失

以末时刻空间状态 $\mathbf{h}_{L,i}^S$ 与时间状态 $\mathbf{h}_i^T$ 完成第二级融合：

$$\mathbf{g}_i = \text{sigmoid}(\mathbf{W}_g[\mathbf{h}_{L,i}^S \parallel \mathbf{h}_i^T] + \mathbf{b}_g), \quad (33)$$

$$\mathbf{h}_i = \mathbf{g}_i \odot \mathbf{h}_{L,i}^S + (\mathbf{1} - \mathbf{g}_i) \odot \mathbf{h}_i^T, \quad (34)$$

$$\hat{\mathbf{y}}_{i,1:H} = f_{\phi_k}(\mathbf{h}_i), \quad i \in \mathcal{V}_k. \quad (35)$$

其中 f_{ϕ_k} 为两层本地 MLP。为避免 L_1 与 Huber 线性组合引入不可辨识的损失权重，采用全局光滑的 Pseudo-Huber（Charbonnier 型）稳健损失 [9]

$$\rho_\kappa(e) = \kappa^2 \left(\sqrt{1 + \left(\frac{e}{\kappa} \right)^2} - 1 \right), \quad \kappa > 0. \quad (36)$$

令 $e_{bhi} = y_{bhi} - \hat{y}_{bhi}$ ，客户端 k 的纯稳健预测目标为

$$\mathcal{L}_k(\boldsymbol{\theta}, \phi_k) = \frac{1}{Z_k} \sum_{b=1}^B \sum_{h=1}^H \sum_{i \in \mathcal{V}_k} m_i w_i \rho_\kappa(e_{bhi}), \quad Z_k = \sum_{b=1}^B \sum_{h=1}^H \sum_{i \in \mathcal{V}_k} m_i w_i. \quad (37)$$

该函数在全实数域二阶连续可微。在小残差区域，其 Taylor 展开和导数满足

$$\rho_\kappa(e) = \frac{1}{2}e^2 + \mathcal{O}(e^4), \quad e \rightarrow 0, \quad (38)$$

$$\rho'_\kappa(e) = \frac{e}{\sqrt{1 + (e/\kappa)^2}}, \quad |\rho'_\kappa(e)| \leq \kappa, \quad (39)$$

$$\rho''_\kappa(e) = (1 + (e/\kappa)^2)^{-3/2} > 0. \quad (40)$$

因此，零残差邻域保留平方损失的平滑曲率，使本地联邦迭代方向稳定；当 $|e| \gg \kappa$ 时，损失本身渐近线性而梯度幅值有界于 κ ，可抑制高幅值尖峰负荷产生的异常回传梯度。这里必须区分“损失线性增长”与“梯度线性增长”：后者对 Pseudo-Huber 不成立。 κ 仅使用验证集选择。所有损失和指标均在反标准化后的有效负荷节点上报告。

4 联邦优化、个性化与差分隐私

4.1 FedProx 共享骨干

第 r 轮服务器选取客户端集合 $\mathcal{S}_r$ ，广播共享编码器 θ^r 。客户端 k 从 (θ^r, ϕ_k^r) 出发执行 E 个本地 epoch，其优化目标为

$$\min_{\theta, \phi_k} \mathcal{J}_k^r(\theta, \phi_k) = \mathcal{L}_k(\theta, \phi_k) + \frac{\mu}{2} \|\theta - \theta^r\|_2^2. \quad (41)$$

近端项仅约束共享编码器，避免本地参数被强行拉回全局模型。令 n_k^{eff} 为客户端 k 去重和掩码后的有效训练样本数，上传本地编码器 $\theta_k^{r,E}$ 后，服务器聚合为

$$\theta^{r+1} = \sum_{k \in \mathcal{S}_r} \frac{n_k^{\text{eff}}}{\sum_{j \in \mathcal{S}_r} n_j^{\text{eff}}} \theta_k^{r,E}. \quad (42)$$

FedAvg 是式 (41) 中 $\mu = 0$ 的基线。Local-only 不上传参数；Centralized 仅作为同数据访问假设下的精度参照，不能被写成隐私方法。

FedProx 近端系数 μ 与后续用户级裁剪阈值 C 不是相互独立的超参数。定义客户端原始更新、裁剪缩放因子和裁剪后更新为

$$\Delta_k^r = \theta_k^{r,E} - \theta^r, \quad (43)$$

$$a_k^r = \min \left\{ 1, \frac{C}{\|\Delta_k^r\|_2} \right\}, \quad (44)$$

$$\overline{\Delta}_k^r = a_k^r \Delta_k^r. \quad (45)$$

较大的 μ 会在本地优化阶段把共享参数拉向 θ^r ，较小的 C 又会在上传阶段缩短剩余更新，二者可能形成“双重收缩”。若异构客户端的 $\|\Delta_k^r\|_2$ 系统性更大，其 $a_k^r < 1$ 的频率也更高。对于非隐私聚合权重 p_k^r ，裁剪相对未裁剪聚合引入的条件偏差为

$$\mathbf{b}_{\text{clip}}^r = \sum_{k \in \mathcal{S}_r} p_k^r (a_k^r - 1) \overline{\Delta}_k^r, \quad p_k^r = \frac{n_k^{\text{eff}}}{\sum_{j \in \mathcal{S}_r} n_j^{\text{eff}}}. \quad (46)$$

该偏差不只是更新幅值减小：不同客户端具有不同的 a_k^r 时，聚合方向也会改变，可能抑制少数客户端特有的预测方向并使近端引导偏离其局部最优。因而 C 与 μ 必须进行二维敏感性分析，并逐轮记录每个客户端的原始更新范数、 a_k^r 、裁剪指示、裁剪率及误差。第 5.2 节的最差 10% 客户端误差应与这些梯度统计量联动分析，而不能仅以“Non-IID 较强”作事后解释。

4.2 威胁模型与正式隐私机制

联邦学习只保证原始负荷不直接上传；模型更新仍可能泄露统计信息。本文将隐私实验明确划分为两种设置：

- **默认推荐：**服务器通过安全聚合仅得到裁剪后更新的和，再施加中心化用户级高斯机制；其保护对象是一个客户端的参与与本地数据集变化。
- **可选对照：**每个客户端在上传前独立扰动更新。该设置保护更强但噪声更大，必须单独命名，不能与中心化 DP 混报。

默认中心化用户级 DP 实验采用**均匀客户端均值**，避免样本量权重改变用户级敏感度；式 (42) 的样本量加权仅作为非 DP 对照。令

$$m_r = |\mathcal{S}_r|. \quad (47)$$

使用式 (45) 后，安全聚合与高斯机制释放的全局更新严格写为

$$\tilde{\Delta}^r = \frac{1}{m_r} \sum_{k \in \mathcal{S}_r} \bar{\Delta}_k^r + \xi^r, \quad (48)$$

$$\xi^r \sim \mathcal{N}\left(\mathbf{0}, \frac{\sigma^2 C^2}{m_r^2} \mathbf{I}\right), \quad (49)$$

$$\theta^{r+1} = \theta^r + \eta_s \tilde{\Delta}^r. \quad (50)$$

等价地，可以先对裁剪更新之和加入协方差为 $\sigma^2 C^2 \mathbf{I}$ 的噪声，再整体除以 m_r ；实现中不得只缩放信号而遗漏噪声的 m_r^{-1} 缩放。在 add/remove-one 客户端邻接关系下，裁剪和的 ℓ_2 敏感度为 C ，均值敏感度为 C/m_r ；在 replace-one 邻接关系下，上界可达 $2C/m_r$ 。代码、噪声生成与 accountant 必须使用同一邻接定义。只要敏感度与噪声同步除以 m_r ，噪声倍率 σ 本身不因求均值而改变。

安全聚合的信任语义也须显式限定：若服务器先看到未加噪的聚合和再自行加噪，则 DP 只保护后续发布结果，不能保护该未加噪和免受服务器观察。要对诚实但好奇的服务器主张用户级 DP，噪声必须由可信聚合模块在释放前加入，或由客户端以可验证的分布式噪声协议共同生成；否则只能声称安全聚合隐藏了单个更新。

客户端采样率定义为

$$q = \frac{m_r}{K}, \quad (51)$$

总通信轮数为 R 。对任意 Rényi 阶数 $\alpha > 1$ ，与实际采样机制匹配的 accountant 给出每轮隐私损失 $\rho_\alpha(q, \sigma)$ ，总预算转换为

$$\varepsilon(\delta) = \min_{\alpha > 1} \left\{ R \rho_\alpha(q, \sigma) + \frac{\log(1/\delta)}{\alpha - 1} \right\}, \quad \delta = 10^{-5}. \quad (52)$$

不得用近似口算替代 accountant 输出。每个 DP 配置、运行日志、结果表与图注必须完整记录审计六元组

$$\mathfrak{P}_{\text{DP}} = (C, \sigma, q, R, \delta, \varepsilon), \quad (53)$$

并同时记录：add/remove-one 或 replace-one 邻接关系、客户端采样机制、噪声加入位置、是否使用安全聚合、accountant 包名称、精确语义版本、源码提交哈希和本项目调用代码的提交哈希。版本或哈希字段为空的结果不得进入正式 DP 结论；本文不在缺少运行环境证据时虚构 accountant 版本。

4.3 通信与计算记录

若共享编码器具有 P_θ 个参数、每参数以 b 字节传输，则每轮双向通信量近似为

$$\text{Comm}(r) \approx 2 |\mathcal{S}_r| P_\theta b, \quad \text{Comm}_{\text{total}} = \sum_{r=1}^R \text{Comm}(r). \quad (54)$$

除精度外，实验应保存参数量、每轮通信 MB、总通信 GB、本地 epoch、最佳验证轮次和单轮训练时间。个性化头不上传，因此不计入式 (54) 的共享传输量。

5 实验设计、评价指标与统计规范

5.1 分阶段验证原则

实验按“先预测骨干、后联邦异构、再差分隐私”的顺序推进。每一个表格只回答一个科学问题，不允许同时改变图结构、融合方式、联邦算法、提前停止规则和隐私噪声。

表 3: 实验矩阵与控制变量

阶段	比较对象	固定条件	主要输出
S0 数据与基线	Persistence、GRU/LSTM、Transformer、GWNNet、AGCRN、MTGNN	同一时间划分、视距、目标节点、指标代码及可比参数/训练预算	每视距 MAE、RMSE、WAPE、sMAPE
S1 结构消融	Base GAT; + 边编码; + 空间门控; + 功能图; 完整骨干	无 DP、集中式或统一训练预算	模块增益、门控分布、参数量
S2 联邦异构	Local-only、FedAvg、FedProx、FedProx+Local Head	选定骨干、相同客户端划分和轮数	平均误差、最差客户端、Jain 指数、收敛曲线
S3 隐私效用	$\varepsilon \in \{\infty, 10, 5, 2\}$	固定骨干、固定 K, E, R 与 accountant	指标- ε 曲线、通信量、噪声代价
S4 稳健性	原始/启发式填充/扰动图; $K \in \{4, 8, 12\}$; 唯一曲线评估	已确定的最优验证配置	拓扑、重复曲线和客户端数敏感性

GWNNet、AGCRN 与 MTGNN 分别代表扩张时序卷积加自适应邻接、节点自适应图卷积循环网络及图结构学习多变量预测三类主流时空图基线 [5, 6, 7]。三者必须使用同一训练/验证/测试边界、 $L = 96$ 的历史窗口、 $H = 12$ 的预测视距、相同 92 节点目

标掩码、反标准化流程与指标实现。若原始参数量差异超过预注册容差，应同时报告原始配置和宽度匹配配置；早停耐心值、最大 epoch、随机种子及超参数搜索次数保持一致。否则，图基线差异将同时混入模型容量与搜索预算，不能归因为空间建模机制。

5.2 评价指标

对全部测试样本、预测步和有效节点的索引集合记为 Ω ，并记 $M = \sum_{(b,h,i) \in \Omega} m_i w_i$ 。四项主指标定义为

$$\text{MAE} = \frac{1}{M} \sum_{(b,h,i) \in \Omega} m_i w_i |y_{bhi} - \hat{y}_{bhi}|, \quad (55)$$

$$\text{RMSE} = \sqrt{\frac{1}{M} \sum_{(b,h,i) \in \Omega} m_i w_i (y_{bhi} - \hat{y}_{bhi})^2}, \quad (56)$$

$$\text{WAPE} = 100\% \times \frac{\sum_{(b,h,i) \in \Omega} m_i w_i |y_{bhi} - \hat{y}_{bhi}|}{\sum_{(b,h,i) \in \Omega} m_i w_i |y_{bhi}| + \epsilon_y}, \quad (57)$$

$$\text{sMAPE} = \frac{100\%}{M} \sum_{(b,h,i) \in \Omega} \frac{2m_i w_i |y_{bhi} - \hat{y}_{bhi}|}{|y_{bhi}| + |\hat{y}_{bhi}| + \epsilon_y}. \quad (58)$$

其中 $\epsilon_y > 0$ 仅防止分母为零，并在所有模型中保持一致。MAPE 可作为与已有代码对接的补充项：

$$\text{MAPE} = \frac{100\%}{M} \sum_{(b,h,i) \in \Omega} \frac{m_i w_i |y_{bhi} - \hat{y}_{bhi}|}{\max(|y_{bhi}|, \eta_y)}. \quad (59)$$

必须报告阈值 η_y ；禁止使用 $100 - \text{MAPE}$ 作为所谓“Accuracy”，因为它不是回归准确率且可能失去物理意义。

联邦实验还报告客户端宏平均误差 $\bar{E}_{\text{client}} = K^{-1} \sum_k E_k$ 、最差 10% 客户端误差分位数，以及基于客户端效用 $u_k = 1/(E_k + \epsilon_y)$ 的 Jain 指数：

$$J = \frac{\left(\sum_{k=1}^K u_k\right)^2}{K \sum_{k=1}^K u_k^2}. \quad (60)$$

5.3 统计检验与复现协议

每个核心模型使用同一组至少 5 个随机种子，报告均值、标准差和每个视距 $h \in \{1, 4, 12\}$ 的指标。对模型 A, B ，按测试日区块形成配对差值

$$d_d = E_d(A) - E_d(B), \quad \bar{d} = \frac{1}{D} \sum_{d=1}^D d_d, \quad (61)$$

进行 2000 次配对日区块 Bootstrap，并以百分位法或 BCa 法报告 $\bar{d}$ 的 95% 置信区间，所用方法须预先固定。只有区间不跨零且效应量满足预先约定的实际阈值时，才可形成

证据等级 D 的“优于”结论。每条此类结论必须采用“模型 A 相对模型 B 的配对区块差异均值为 $\bar{d}$, 95% CI 为 $[l, u]$ ”的可核验格式；缺少任一数值时只能称为趋势或初步信号。所有运行应保存：数据哈希、时间划分、图配置、客户端划分、随机种子、配置文件、代码提交标识和最优验证轮次。DP 运行还必须保存式 (53) 六元组及 accountant 精确版本和提交哈希。

5.4 推荐起始配置

表 4 是起始而非最终超参数。搜索仅在验证集执行；最终测试不得反向用于调整这些值。

表 4: 推荐起始超参数与搜索范围

项目	起始值	搜索与说明
历史/预测窗口	$L = 96, H = 12$	额外测试 (48, 6) 与 (192, 12) 的时间尺度敏感性
嵌入维度/注意力头	$d = 64, M_P = 4$	$d \in \{32, 64, 128\}$, 参数量必须同步报告
Transformer	2 层、4 头、dropout 0.1	因果掩码固定；不把 T-GAT 与 Transformer 同时列为主模型
本地功能图嵌入维度	$d_a = 16$	$d_a \in \{8, 16, 32\}$ ；报告每客户端关系参数量及过拟合差距
优化器	AdamW, 学习率 10^{-3}	学习率 $\{3 \times 10^{-4}, 10^{-3}, 3 \times 10^{-3}\}$
FedProx 系数	$\mu = 10^{-3}$	$\{0, 10^{-4}, 10^{-3}, 10^{-2}\}$ ；0 即 FedAvg
本地 epoch/轮数	$E = 1 \sim 3, R =$ 50	与通信预算共同报告，不能只比较最佳轮次
DP 参数	以 accountant 反 求 σ	完整记录 $(C, \sigma, q, R, \delta, \varepsilon)$ 、邻接约定与源码版本

6 已有初步结果的规范解读与最终模型决策

6.1 单次消融结果与负协同诊断协议

表 5 仅记录已有单次运行。各模型提前停止轮次和报告隐私预算不完全一致，且没有多种子标准差，因此不能作为最终统计结论。现有记录没有给出完整的 $(C, \sigma, q, R, \delta, \varepsilon)$ 六元组、邻接约定、采样机制及 accountant 版本/源码哈希，故表中 ε 仅为历史日志值，当前不可审计且不得用于正式隐私比较。

表 5: 已有单次初步消融结果 (仅用于确定复验优先级)

编号	模型	MAPE/%	RMSE	最佳轮	日志 ε
1	纯 Transformer	13.42	0.5040	7	1.404
4	+ 基础时空注意力	13.52	0.5041	7	1.404
5	+ 边编码	12.99	0.4997	13	1.563
6	+ T-GAT	13.31	0.5024	8	1.457
7	+ ST 融合	13.18	0.4986	9	1.510
8	+ 边编码 + T-GAT	13.23	0.5004	7	1.404
9	全增强	13.74	0.5008	9	1.510

可支持的、且仅限于证据等级 B 的判断是：边编码在 MAPE 上出现正向信号；ST 融合在 RMSE 上出现正向信号；T-GAT 的额外收益较弱。模型 9 的 MAPE 相对模型 1 增加 0.32 个百分点、相对模型 5 增加 0.75 个百分点；其 RMSE 相对模型 5 增加 0.0011，但相对模型 1 减少 0.0032。因此，“负协同”是**指标相关的待检验假设**，不能简化为全面性能下降，也不能仅归因于超参数未调好。不能支持的判断还包括“模型 7 全面最优”“ $\varepsilon < 10$ 已证明隐私充分”或“OGIF-GAT/MSTC-GAT 已被完整复现”。主模型候选采用**边感知物理 GAT + 本地静态功能图 + 空间/时空门控 + Temporal Transformer + FedProx + Local Head**；T-GAT 从主链路移除，仅作为可选对照；边编码与时空融合的组合必须被单独复验。

6.1.1 时空双级门控系数分布与饱和度诊断协议

为区分模块冗余、表征退化与梯度冲突，固定饱和阈值 $\tau_s = 0.05$ 。将第一层空间门控的全部标量元素展平为集合 $\Gamma = \{\gamma_u\}_{u=1}^{M_\gamma}$ ，将第二层时空门控展平为 $\mathcal{Q} = \{g_v\}_{v=1}^{M_g}$ 。在验证集和测试集上分别计算

$$\text{Sat}_0(\Gamma) = \frac{1}{M_\gamma} \sum_{u=1}^{M_\gamma} \mathbb{I}(\gamma_u \leq \tau_s), \quad \text{Sat}_1(\Gamma) = \frac{1}{M_\gamma} \sum_{u=1}^{M_\gamma} \mathbb{I}(\gamma_u \geq 1 - \tau_s), \quad (62)$$

$$\text{Sat}_0(\mathcal{Q}) = \frac{1}{M_g} \sum_{v=1}^{M_g} \mathbb{I}(g_v \leq \tau_s), \quad \text{Sat}_1(\mathcal{Q}) = \frac{1}{M_g} \sum_{v=1}^{M_g} \mathbb{I}(g_v \geq 1 - \tau_s). \quad (63)$$

同时报告两级门控的均值、标准差以及 1%、5%、50%、95%、99% 分位数。门熵定义为

$$\mathcal{H}(\mathcal{A}) = -\frac{1}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} [a \log(a + \epsilon_g) + (1 - a) \log(1 - a + \epsilon_g)], \quad \mathcal{A} \in \{\Gamma, \mathcal{Q}\}, \quad (64)$$

其中 $\epsilon_g > 0$ 仅用于数值稳定。高边界饱和率与低门熵共同说明门控近似常数选路，但不能单独证明另一分支无效。

表征冗余使用中心化线性 CKA 计算物理/功能分支及空间/时间分支的相似度。令批次展平并中心化后的表示为 $\bar{\mathbf{H}}_a, \bar{\mathbf{H}}_b$ ，则

$$\text{CKA}(a, b) = \frac{\|\bar{\mathbf{H}}_a^\top \bar{\mathbf{H}}_b\|_F^2}{\|\bar{\mathbf{H}}_a^\top \bar{\mathbf{H}}_a\|_F \|\bar{\mathbf{H}}_b^\top \bar{\mathbf{H}}_b\|_F}. \quad (65)$$

接近 1 的 CKA 仅在分支性能亦相近且门控缺少选择性时作为冗余证据。梯度冲突则在相同 mini-batch 上，以总损失对两个待融合分支表示的梯度余弦衡量：

$$\text{GCS}(a, b) = \frac{\langle \text{vec}(\nabla_{\mathbf{H}_a} \mathcal{L}), \text{vec}(\nabla_{\mathbf{H}_b} \mathcal{L}) \rangle}{\|\nabla_{\mathbf{H}_a} \mathcal{L}\|_F \|\nabla_{\mathbf{H}_b} \mathcal{L}\|_F + \epsilon_g}. \quad (66)$$

持续为负的 GCS 表示两个分支对下游误差提出相反更新方向。正式诊断按以下证据链执行：门控双侧饱和率识别常数选路；门熵刻画选择不确定性；CKA 检查表征复制或塌缩；GCS 定位优化冲突；最后用逐模块去除实验验证因果归因。只有这些统计量在同一种子配对下与模型 9 的误差恶化共同出现，才可把负协同归因于门控饱和、表征冗余或梯度冲突。

7 职责分配、八周计划与交付规范

7.1 三人职责分配

三位成员共享统一仓库、数据配置和结果目录；公共数据管线、指标实现和聚合接口的修改必须由另一位成员复核。

表 6: 匿名职责分配

职责标识	主责任	具体可验收任务
成员 A	数据、评估与集成	生成数据审计报告；实现时间切分、节点掩码、重复组权重与指标；维护实验配置、结果汇总、图表和最终文档
成员 B	时空模型	实现边感知物理 GAT、本地静态功能图、两级门控与 Temporal Transformer；完成集中式基线和结构消融；输出门控饱和、CKA 与梯度冲突分析
成员 C	联邦与隐私	实现客户端划分、FedAvg、FedProx 与本地头；实现安全聚合接口、裁剪、噪声和 RDP accountant；统计通信和客户端公平性

7.2 八周实施计划

表 7: 八周里程碑与验收产物

周期	里程碑	验收产物	责任
第 1 周	数据冻结	NPZ 字段审计、哈希、目标掩码、重复组、原始图/启发式填充图配置	A
第 2 周	时间与图基线	Persistence、GRU/LSTM、Transformer、GWNNet、AGCRN、MTGNN 与统一指标脚本	A+B
第 3 周	物理图模块	Base GAT、边属性、边编码消融与单元测试	B
第 4 周	双图骨干	功能图、门控统计、PA-STFed 集中式消融	B
第 5 周	联邦基线	$K = 8$ 划分、Local-only、FedAvg、FedProx 与 Non-IID 报告	C
第 6 周	个性化与隐私	Local Head、固定目标 ϵ 、通信和 accountant 日志	C
第 7 周	重复与敏感性	五种子、区块 Bootstrap、 K 与拓扑/重复曲线敏感性	A+B+C
第 8 周	结项交付	可复现仓库、最终图表、报告、答辩 PPT 与问答清单	A+B+C

7.3 结果文件与验收清单

每次运行的唯一标识应编码模型、种子、客户端划分与隐私配置，例如 `pastfed_seed01_k8_eps5`。每个结果目录必须保存：`config.yaml`、数据哈希、逐轮 CSV、最优验证 checkpoint、测试 JSON、参数量、通信量和隐私会计记录。结项前逐项核验：

- 训练、验证、测试窗口不重叠，标准化统计量只来自训练集；
- 恒零节点不计入误差；重复曲线的三种评估口径均已报告；
- 原始图、启发式填充图和扰动图均有独立配置与结果；
- 所有核心比较使用相同种子、相同时间切分和可比训练/隐私预算；
- DP 结果包含 $(C, \sigma, q, R, \delta, \epsilon)$ 、邻接关系、采样机制、噪声位置、安全聚合状态以

及 accountant 包名、精确版本和源码提交哈希；

- 文中每个“优于”结论均能定位到配对日区块 Bootstrap 的差异均值、95% 置信区间和完整实验表。

8 风险、局限性与结论

8.1 主要风险与处置

表 8: 主要风险与应对

等级	风险	处置
高	SmartDS 为合成数据, 非真实现场采集	在题目应用边界内表述为合成微观配电网验证; 不宣传真实部署; 后续论文阶段再补真实数据
高	启发式拓扑填充不是官方拓扑真值	原始、启发式填充、扰动图三组敏感性; 边属性记录桥边路径计数; 不以填充结果单独宣称物理发现
高	92 节点仅含 56 条唯一曲线	使用重复组权重与唯一曲线复验, 避免重复节点夸大样本量和联邦权重
中	模块堆叠产生负协同	按 S1 单因素消融推进; 执行双级门控饱和率、门熵、CKA 与梯度余弦诊断; 以配对去除实验验证归因
中	DP 实现形式化不足	固定邻接、采样、裁剪、噪声位置和 accountant 版本; 保存六元组与逐轮预算; 可信或分布式噪声在释放前加入时才主张对服务器的用户级 DP
中	小差异被随机波动误判	五个种子、配对区块 Bootstrap、报告置信区间和效应量

8.2 结论

本文给出一个以证据链为中心的结项方案。其技术核心不是无约束地增加模块, 而是在 SmartDS 经核验的合成数据约束下, 以边感知物理图处理可解释的拓扑传播、以客户端本地静态功能图处理行为相似性、以因果 Transformer 处理历史依赖, 并通过两级门控检验各表征的互补性。联邦部分以 FedProx 和不聚合的本地关系嵌入/预测头分别处理共享骨干的客户端漂移与区域差异; 隐私部分以校准到客户端均值敏感度的高斯机制和锁定版本的 accountant 形成可审计预算。

项目的最终可信度取决于三个条件: 第一, 所有拓扑假设、重复曲线与合成数据局限均被公开; 第二, 结构、联邦、隐私和稳健性实验以可复现的控制变量逐层验证; 第三, 结论强度严格匹配统计证据。满足这些条件后, 项目可形成一套逻辑闭合、实现完整、能够经受结项答辩追问的配电网时空联邦预测方案。

A 符号说明

符号	定义
T, N, N_ℓ	总时间点数、编码节点数、非零负荷目标节点数
L, H, B	历史窗口长度、预测窗口长度、mini-batch 样本数
$K, \mathcal{S}_r, E, R$	客户端总数、第 r 轮参与客户端集合、本地 epoch、通信轮数
θ, ϕ_k	共享时空变换参数向量、客户端 k 的本地关系嵌入与预测头参数向量
$\mathcal{G}^{\text{raw}}, \mathcal{G}^{\text{inf}}$	原始拓扑图、启发式拓扑填充图
m_i, w_i	非零负荷节点掩码、重复曲线组权重
$C, \sigma, q, R, \delta, \varepsilon$	DP 裁剪阈值、噪声倍率、客户端采样率、通信轮数、失效概率、隐私预算
μ	FedProx 近端正则系数
$\epsilon_s, \epsilon_y, \eta_y$	标准化、比例指标和 MAPE 分母稳定常数/阈值

参考文献

- [1] C. Mateo, F. Postigo, F. de Cuadra, et al. Building Large-Scale U.S. Synthetic Electric Distribution System Models. *IEEE Transactions on Smart Grid*, 2020. DOI: <https://doi.org/10.1109/TSG.2020.3001495>.
- [2] Open Energy Data Initiative. SMART-DS Synthetic Electrical Network Data OpenDSS Models for SFO, GSO, and AUS. <https://data.openei.org/submissions/2981>.
- [3] C. Wei, D. Pi, M. Ping, H. Zhang. Short-term Load Forecasting Using Spatial-temporal Embedding Graph Neural Network. *Electric Power Systems Research*, 2023. DOI: <https://doi.org/10.1016/j.epsr.2023.109873>.
- [4] P. Veličković, G. Cucurull, A. Casanova, et al. Graph Attention Networks. *ICLR*, 2018. <https://openreview.net/forum?id=rJXMpikCZ>.
- [5] Z. Wu, S. Pan, G. Long, J. Jiang, C. Zhang. Graph WaveNet for Deep Spatial-Temporal Graph Modeling. *IJCAI*, 2019. DOI: <https://doi.org/10.24963/ijcai.2019/264>.
- [6] L. Bai, L. Yao, C. Li, X. Wang, C. Wang. Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting. *NeurIPS*, 2020. <https://proceedings.neurips.cc/paper/2020/hash/ce1aad92b939420fc17005e5461e6f48-Abstract.html>.
- [7] Z. Wu, S. Pan, G. Long, J. Jiang, X. Chang, C. Zhang. Connecting the Dots: Multivariate Time Series Forecasting with Graph Neural Networks. *ACM SIGKDD*, 2020. DOI: <https://doi.org/10.1145/3394486.3403118>.
- [8] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention Is All You Need. *NeurIPS*, 2017. <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.
- [9] P. Charbonnier, L. Blanc-Féraud, G. Aubert, M. Barlaud. Two Deterministic Half-Quadratic Regularization Algorithms for Computed Imaging. *IEEE ICIP*, 1994. DOI: <https://doi.org/10.1109/ICIP.1994.413553>.
- [10] X. Xu, L. Fei, Y. Zhao, X. Lü. Optimal Graph Information Fused Graph Attention Network for Traffic Flow Forecasting. *Journal of Advanced Transportation*, 2025. DOI: <https://doi.org/10.1155/atr/5195875>.
- [11] J. Liu, Y. Wang, J. Zhu, et al. A Multilayer Spatiotemporal Correlation-Aware Graph Attention Network for Traffic Flow Prediction. *IEEE Transactions on Neural*

- Networks and Learning Systems*, 2025. DOI: <https://doi.org/10.1109/TNNLS.2025.3630903>.
- [12] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. A. y Arcas. Communication-Efficient Learning of Deep Networks from Decentralized Data. *AISTATS*, 2017. <https://proceedings.mlr.press/v54/mcmahan17a.html>.
- [13] T. Li, A. K. Sahu, M. Zaheer, et al. Federated Optimization in Heterogeneous Networks. *Proceedings of Machine Learning and Systems*, 2020. <https://proceedings.mlsys.org/paper/2020/hash/38af86134b65d0f10fe33d30dd76442e-Abstract.html>.
- [14] L. Collins, H. Hassani, A. Mokhtari, S. Shakkottai. Exploiting Shared Representations for Personalized Federated Learning. *ICML*, 2021. <https://proceedings.mlr.press/v139/collins21a.html>.
- [15] C. Briggs, Z. Fan, P. Andras. Federated Learning for Short-Term Residential Load Forecasting. *IEEE Open Access Journal of Power and Energy*, 2022. DOI: <https://doi.org/10.1109/OAJPE.2022.3206220>.
- [16] J. D. Fernández, S. P. Menci, C. M. Lee, A. Rieger, G. Fridgen. Privacy-preserving Federated Learning for Residential Short-term Load Forecasting. *Applied Energy*, 2022. DOI: <https://doi.org/10.1016/j.apenergy.2022.119915>.
- [17] M. Abadi, A. Chu, I. Goodfellow, et al. Deep Learning with Differential Privacy. *ACM CCS*, 2016. DOI: <https://doi.org/10.1145/2976749.2978318>.
- [18] I. Mironov. Rényi Differential Privacy. *IEEE Computer Security Foundations Symposium*, 2017. DOI: <https://doi.org/10.1109/CSF.2017.11>.
- [19] K. Bonawitz, V. Ivanov, B. Kreuter, et al. Practical Secure Aggregation for Privacy-Preserving Machine Learning. *ACM CCS*, 2017. DOI: <https://doi.org/10.1145/3133956.3133982>.